# PROJECT OVERVIEW

**Judul Project:** AutoData
**Tema:** Productivity & Smart Business

**Deskripsi Singkat:**

AutoData adalah asisten analisis data berbasis percakapan yang membantu junior data analyst dan tim kecil melakukan screening awal terhadap dataset CSV milik mereka, mulai dari eksplorasi data, segmentasi, rekomendasi target prediksi, sampai perbandingan beberapa model machine learning, tanpa harus menulis kode. AutoData dibangun di atas IBM Langflow, dengan integrasi IBM Bob melalui MCP dan akses pengguna lewat Telegram. Hal yang membedakan AutoData dari asisten AI data pada umumnya adalah Trust Layer: setiap hasil model dibandingkan dengan baseline sederhana dan diberi label kualitas (BAIK, SEDANG, atau KURANG MEMUASKAN) yang dihitung oleh kode Python, bukan penilaian subjektif dari LLM.

**Problem Statement:**

Tim kecil dan analis junior biasanya sudah punya dataset, tapi belum punya cara praktis untuk menentukan langkah analisis awal, memilih target yang tepat, atau mengetahui apakah model yang mereka buat benar-benar memberikan hasil yang berarti. Dari survei awal ke 4 calon pengguna, 3 dari 4 responden merasa sulit menentukan pendekatan analisis yang tepat. Seluruh responden (4 dari 4) sudah memakai AI generatif seperti ChatGPT atau Gemini sebagai bantuan analisis, tapi 3 dari 4 tetap mengaku ragu dengan keandalan hasil yang diberikan AI tersebut. Ini menunjukkan ada kebutuhan validasi dan konteks tambahan yang belum terpenuhi oleh alat AI generik yang sudah ada.

**Target User:**

Mahasiswa, analis junior, dan pelaku usaha kecil yang punya data tabular (CSV) tapi tidak punya latar belakang data science yang kuat, dan butuh panduan terstruktur untuk memahami data mereka sebelum lanjut ke analisis atau keputusan yang lebih jauh.

**Fitur Utama:**

1. EDA otomatis: ringkasan ukuran data, tipe kolom, missing value, dan duplicate rows.
2. Segmentasi otomatis lewat clustering K-Means untuk menemukan pola dalam data. Hasilnya dijelaskan sebagai pola statistik, bukan kategori pasti.
3. Rekomendasi dan konfirmasi cleaning: saran penanganan missing value (mean, median, modus, atau hapus) dan duplicate (hapus atau pertahankan) yang bisa disetujui atau diubah pengguna.
4. Rekomendasi target: kandidat kolom target dengan penjelasan kegunaan praktisnya, yang dikonfirmasi langsung oleh pengguna.
5. Machine learning screening dengan deteksi otomatis klasifikasi atau regresi, membandingkan tiga model (Random Forest, Logistic/Linear Regression, dan Gradient Boosting).
6. Trust Layer: perbandingan dengan baseline sederhana dan label kualitas model yang deterministik.
7. Laporan otomatis: hasil analisis lengkap dibuat di Google Docs atas permintaan pengguna.
8. Akses multi-channel: Telegram sebagai kanal utama pengguna, dan IBM Bob sebagai jalur integrasi dan pengujian lewat MCP.