AutoData

Technical Documentation

Conversational Data Analysis & ML Screening Assistant

PRODUCTIVITY & SMART BUSINESS

Informasi	Detail
Developer	Alditia Muhamad Pirmansyah
Event	Hacktiv8 × IBM SkillsBuild National Hackathon 2026
Version	1.0
Last Updated	8 Oktober 2026

Dokumen ini berfokus pada bukti teknis prototype, integrasi, testing, dan Responsible AI.

1. Executive Summary

AutoData adalah asisten analisis data dan machine learning berbasis percakapan yang membantu junior data analyst dan small teams melakukan initial analysis dari dataset CSV.

AutoData menggabungkan interaksi pengguna melalui IBM Bob dengan workflow analisis di IBM Langflow melalui MCP. Workflow menggunakan Python, pandas, dan scikit-learn untuk melakukan pemeriksaan kualitas data, exploratory analysis, clustering, rekomendasi cleaning, pemilihan target, machine learning screening, perbandingan dengan baseline, dan pembuatan laporan.

Dokumen ini menunjukkan bahwa AutoData merupakan prototype yang benar-benar dibangun dan diuji, terintegrasi dengan IBM Bob, MCP, dan IBM Langflow, serta memiliki batasan dan mekanisme Responsible AI yang terdokumentasi.

Status prototype: telah diuji menggunakan 3 dataset.

AutoData tidak dirancang untuk menggantikan data scientist atau mengambil keputusan berisiko tinggi secara otomatis. Fokus prototype adalah membantu pengguna melakukan tahap awal analisis secara lebih terstruktur dan memberikan konteks tambahan terhadap hasil model.

2. Problem, Target User & Validation

2.1 Problem

Junior data analyst dan tim kecil sering menerima dataset tanpa mengetahui langkah analisis yang tepat. Mereka perlu memahami kualitas data, menentukan target yang relevan, memilih langkah cleaning, dan menilai apakah hasil model memberikan peningkatan yang berarti dibandingkan pendekatan sederhana.

Tanpa alur yang terarah, proses analisis dapat bergantung pada trial-and-error, tutorial, atau bantuan AI umum yang memberikan hasil tetapi tidak selalu menyediakan konteks yang cukup untuk menilai hasil tersebut.

2.2 Problem Statement

> *Junior data analyst dan small teams yang sedang melakukan analisis awal terhadap dataset perlu menentukan langkah analisis, cleaning, dan target yang sesuai, tetapi sering menghadapi ketidakjelasan mengenai pendekatan yang harus digunakan dan bagaimana menilai hasil model. AutoData membantu pengguna melewati proses tersebut melalui workflow percakapan yang terstruktur sehingga pengguna dapat menghasilkan analisis awal yang disertai konteks baseline dan penjelasan hasil dalam satu sesi percakapan.*

2.3 Target User

- Primary users: Junior Data Analysts dan small teams tanpa in-house data scientist.
- Secondary users: UMKM yang mulai menerapkan pengambilan keputusan berbasis data dan early-stage startups.

2.4 Initial Validation

Validasi awal dilakukan melalui survei terhadap 4 responden.

Temuan	Hasil
Menilai proses menentukan pendekatan analisis sulit/sangat sulit	3/4
Menggunakan AI sebagai bantuan analisis	4/4
Menyatakan kekhawatiran terhadap hasil AI	3/4
Menilai konsep AutoData sangat berguna	4/4

Validasi ini digunakan untuk melihat relevansi awal masalah dan penerimaan terhadap konsep. Dengan n=4, hasil tidak dimaksudkan untuk mewakili populasi atau mengukur usability prototype secara umum.

3. Solution & Differentiation

3.1 Solution

AutoData mengubah proses initial analysis menjadi workflow percakapan yang terstruktur: CSV → Data Quality & EDA → Cleaning Recommendation → User Confirmation → Target Selection → ML Screening → Baseline Comparison → Quality Label → Google Docs Report.

Pengguna tetap memiliki kontrol pada keputusan yang memengaruhi analisis, khususnya pilihan cleaning dan target.

3.2 Differentiation

Karakteristik	Penerapan pada AutoData
Guided	Pengguna diarahkan melalui tahapan analisis dan diberikan kandidat target beserta kegunaan praktisnya.
User-controlled	Rekomendasi cleaning dan target tidak langsung diterapkan tanpa keputusan pengguna.
Baseline-aware	Performa model disertai baseline agar metric memiliki konteks pembanding.

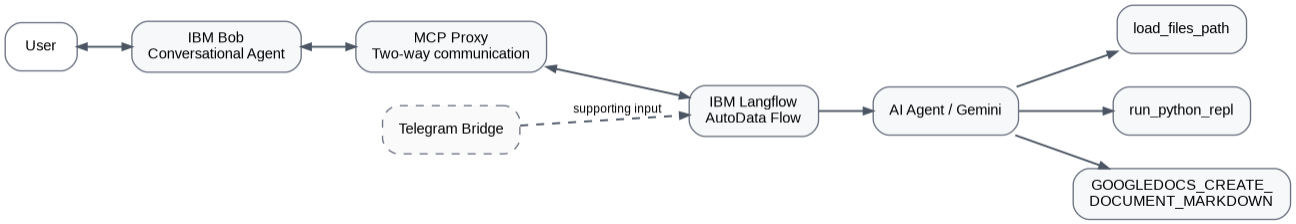
Pendekatan ini berbeda dari asisten AI umum yang memberikan jawaban secara bebas dan analisis manual yang lebih bergantung pada pengetahuan teknis pengguna.

3.3 Business Model

AutoData dirancang menggunakan model freemium. Versi dasar berfokus pada initial analysis dan ML screening, sedangkan pengembangan premium dapat mencakup koneksi database, analysis history, recurring analysis, dan monitoring. Detail model bisnis tersedia pada Idea & Business Canvas.

4. System Overview

4.1 Architecture



Gambar 1. Arsitektur AutoData dan jalur integrasi IBM Bob, MCP, Langflow, Agent, tools, dan Telegram Bridge.

Komponen	Peran
IBM Bob	Antarmuka percakapan dengan pengguna.
MCP Proxy	Penghubung antara Bob dan Langflow.
IBM Langflow	Menjalankan workflow AutoData.
AI Agent	Mengatur percakapan dan pemanggilan tools.
load_files_path	Mengembalikan lokasi file dataset.
run_python_repl	Menjalankan analisis Python.
GOOGLEDOCS_CREATE_DOCUMENT_MARKDOWN	Membuat laporan dari isi Markdown.
Telegram Bridge	Channel end-user yang meneruskan file CSV dan pesan pengguna ke flow Langflow, lalu mengirim kembali respons Agent. Memakai flow yang sama dengan jalur IBM Bob.

4.2 Analysis Workflow



Gambar 2. Workflow dua tahap dengan titik konfirmasi pengguna.

Call 2 tidak dijalankan sebelum target diketahui dan metode cleaning sudah jelas, baik melalui pilihan pengguna maupun rekomendasi default.

5. Features & Example Walkthrough

5.1 Core Features

- Data Quality Analysis: jumlah baris dan kolom, missing values, duplicate rows, tipe data, statistik deskriptif, dan profil dasar kolom melalui hasil eksplorasi dataset.
- Clustering: melihat pola pengelompokan pada data numerik apabila dataset memenuhi kondisi yang diperlukan.
- Cleaning Recommendation: memberikan rekomendasi treatment berdasarkan masalah kualitas data yang benar-benar ditemukan.
- Target Recommendation: memberikan 2-4 kandidat target beserta kegunaan praktisnya.
- Machine Learning Screening: cleaning, task detection, tiga model, metric, baseline, dan quality label.
- Trust Layer: memberikan konteks terhadap hasil model melalui baseline comparison.
- Google Docs Report: menyusun laporan teknis dari hasil analisis yang sudah diperoleh.

5.2 Example Walkthrough

Dataset: bank_transactions_data_edited.csv

Walkthrough ini dijalankan melalui Telegram Bridge ke flow AutoData yang sama. Integrasi IBM Bob dan MCP dibuktikan terpisah pada Appendix C.

Tahap 1: Call 1

AutoData menjalankan EDA, data quality check, dan clustering.

[HASIL WALKTHROUGH AKTUAL: ringkasan Call 1]

Ringkasan Data dan Kualitas Data

- Ukuran dataset: 2.537 baris dan 16 kolom.
- Missing value: 403 nilai kosong yang tersebar di hampir semua kolom. Contohnya TransactionAmount (26 nilai kosong) dan AccountBalance (27 nilai kosong), ditambah beberapa kolom kategorikal.
- Duplicate rows: 21 baris.

Hasil Clustering (3 segmen)

- Segmen 0 (88 data): cenderung memiliki jumlah percobaan login (LoginAttempts) yang tinggi, rata-rata sekitar 4 kali.
- Segmen 1 (1.407 data): cenderung berusia lebih tua (rata-rata sekitar 56 tahun) dengan saldo rekening (AccountBalance) yang terlihat lebih tinggi, rata-rata sekitar 7.052.
- Segmen 2 (925 data): cenderung berusia lebih muda (rata-rata sekitar 28 tahun) dengan saldo yang terlihat lebih rendah, tetapi nominal transaksi (TransactionAmount) terlihat lebih tinggi, rata-rata sekitar 326.

[HASIL WALKTHROUGH AKTUAL: rekomendasi cleaning dan kandidat target]

Rekomendasi Cleaning

- Missing numerik (118 nilai) → Median. Alasan: lebih tahan terhadap nilai ekstrem, misalnya saldo atau nominal transaksi yang sangat tinggi.
- Missing kategorikal (285 nilai) → Modus. Alasan: mengisi nilai kosong dengan kategori yang paling sering muncul.
- Duplicate rows (21 baris) → Hapus. Alasan: agar baris yang sama tidak dihitung berulang.

Kandidat Target (berdasarkan struktur dataset)

1. TransactionAmount: memprediksi nominal transaksi (regresi).
2. AccountBalance: memperkirakan saldo rekening (regresi).
3. TransactionType: memprediksi jenis transaksi (klasifikasi).
4. Channel: memprediksi saluran transaksi yang cenderung digunakan (klasifikasi).

Respons user: "rekomendasi"

AutoData menerima rekomendasi cleaning dan meminta pengguna menentukan target.

Target: AccountBalance

Tahap 2: Call 2

AutoData menjalankan cleaning dan machine learning screening.

Output	Hasil
Target	AccountBalance
Task	Regresi
Random Forest	RMSE 2.949,28, R^2 0,448
Linear Regression / Logistic Regression	RMSE 3.384,13, R^2 0,273
Gradient Boosting	RMSE 2.874,07, R^2 0,476
Baseline	RMSE 3.973,17, R^2 -0,002
Model terbaik	Gradient Boosting (R^2 tertinggi)
Metric	R^2 dan RMSE

Output	Hasil
Quality label	Gradient Boosting: **SEDANG**; Random Forest: **SEDANG**; Linear Regression: **KURANG MEMUASKAN**

6. Technical Implementation

6.1 Technology Stack

Layer	Technology
User interaction	IBM Bob
Integration	MCP
Workflow	IBM Langflow
LLM	Gemini
Data processing	Python
Data analysis	pandas
Machine learning	scikit-learn
Reporting	Google Docs
Supporting input	Telegram Bridge

6.2 Tool Contract

Tool	Fungsi	Tahap
load_files_path	Mendapatkan path dataset.	Awal analisis
run_python_repl	Menjalankan kode Python untuk EDA, cleaning, clustering, dan ML screening.	Call 1 & Call 2
GOOGLEDOCS_CREATE_DOCUMENT_MARKDOWN	Membuat laporan Markdown di Google Docs dari hasil yang sudah tersedia.	Setelah analisis

6.3 Two-Call Design & Preprocessing

Dalam satu sesi analisis untuk satu dataset dan satu target, run_python_repl digunakan maksimal dua kali. Call 1 dijalankan satu kali untuk EDA + Data Quality Check + Clustering. Call 2 dijalankan satu kali untuk Cleaning + Machine Learning Screening. Tidak ada automatic retry setelah error.

Preprocessing pada Call 2 meliputi:

- Train-test split menggunakan rasio 80:20 dengan random_state=42.
- Pada classification, stratified split digunakan ketika distribusi kelas memenuhi kondisi yang diperlukan.
- Mean/median untuk fitur numerik dan modus untuk fitur kategorikal dihitung dari data training setelah split, lalu diterapkan ke data training dan testing.
- Jika metode cleaning yang dipilih adalah drop, baris dengan missing pada fitur yang bersangkutan dihapus sebelum train-test split.
- Missing pada target selalu dihapus dan tidak diimputasi.
- Kolom yang seluruh nilainya missing dihapus otomatis sebelum modeling.
- Encoding kategorikal menggunakan pandas.get_dummies(), kemudian kolom hasil encoding pada data test diselaraskan dengan data training.
- Baseline regression menggunakan rata-rata y_train, sedangkan baseline classification menggunakan proporsi kelas mayoritas pada y_train.

6.4 Task Detection & Model Selection

Target numerik dengan lebih dari 15 nilai unik diperlakukan sebagai regresi. Selain kondisi tersebut, target diperlakukan sebagai classification. Dengan aturan ini, target numerik dengan cardinality rendah seperti rating 1-5 diperlakukan sebagai classification.

Task	Algoritma	Kriteria Model Terbaik
Regresi	Random Forest Regressor; Linear Regression; Gradient Boosting Regressor	R^2 tertinggi
Klasifikasi	Random Forest Classifier; Logistic Regression; Gradient Boosting Classifier	Accuracy tertinggi, lalu Balanced Accuracy sebagai tie-breaker

6.5 Clustering

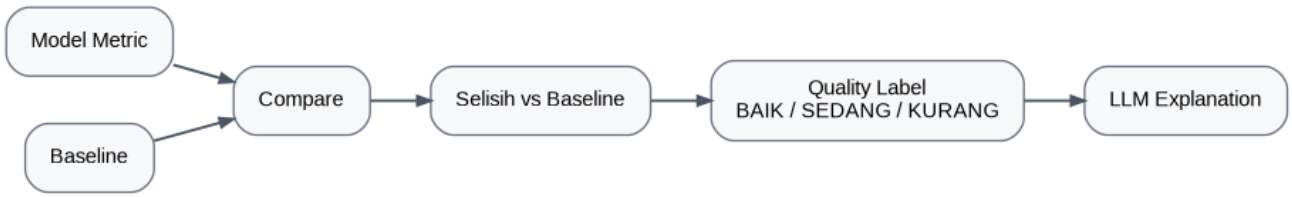
Clustering hanya dijalankan jika tersedia setidaknya dua kolom numerik. Jumlah cluster berada pada rentang minimal 2 dan maksimal 3, dengan random_state=42 dan n_init=10.

7. Trust Layer

7.1 Baseline Comparison

Metric model diberikan konteks melalui baseline sederhana. Baseline digunakan sebagai referensi untuk melihat apakah model memberikan improvement dibandingkan pendekatan pembanding.

7.2 Deterministic Quality Label



Gambar 3. Alur perhitungan metric, baseline, selisih, quality label, dan penjelasan LLM.

Python menghitung metric, baseline, selisih performa, dan quality label berdasarkan aturan yang telah ditetapkan dalam workflow. LLM kemudian menyampaikan dan menjelaskan hasil tersebut kepada pengguna.

7.3 Quality Label Rules

Task	BAIK	SEDANG	KURANG MEMUASKAN
Regresi	R^2 model > R^2 baseline dan $R^2 \geq 0{,}60$	R^2 model > R^2 baseline dan $R^2 \geq 0{,}30$	Selain kondisi tersebut
Klasifikasi	Accuracy ≥ 10 poin persentase di atas baseline	Accuracy 3 sampai <10 poin persentase di atas baseline	Kurang dari 3 poin persentase di atas baseline

Threshold tersebut merupakan heuristic screening rules untuk prototype, bukan standar statistik universal atau jaminan bahwa model siap digunakan di production.

8. Design Decisions, Gotchas & Iteration History

8.1 Design Decisions

- Dua Python Calls: analisis dipisahkan menjadi inspection dan modeling untuk membatasi eksekusi dan mengurangi looping.
- Cleaning setelah konfirmasi: pengguna melihat kondisi data dan rekomendasi sebelum treatment diterapkan.
- Target dikonfirmasi pengguna: Agent tidak menebak target ketika target belum diberikan.
- Report dari hasil yang tersedia: pembuatan Google Docs tidak menjalankan analisis Python ulang.

8.2 Known Gotchas & Edge Cases

Kondisi	Perilaku Prototype
Python interpreter menggunakan import	Interpreter tidak mendukung baris import, sehingga library dipanggil melalui namespace yang sudah tersedia.
Bob dan CSV	Bob tidak menyediakan native CSV upload untuk workflow ini. Integrasi Bob dibuktikan melalui pemanggilan tool MCP, sedangkan pengguna dapat mengirim CSV dan berinteraksi melalui Telegram Bridge.
State Python antar-call	State tidak diasumsikan tersedia, sehingga CSV dibaca kembali pada Call 2.
User hanya mengetik rekomendasi	Rekomendasi cleaning diterima dan Agent meminta target.
Target memiliki nilai kosong	Baris dengan target kosong dihapus sebelum modeling.
Target numerik memiliki ≤15 nilai unik	Target diperlakukan sebagai classification.
Kolom numerik tidak mencukupi	Clustering tidak dijalankan.
Python execution error	Workflow berhenti dan tidak menghasilkan atau mengarang hasil.
Target diganti setelah Call 2	Analisis target baru membutuhkan sesi analisis baru.

8.3 Riwayat Iterasi

- Data Quality Check dan cleaning ditambahkan setelah alur awal untuk membuat pemeriksaan kondisi dataset menjadi bagian eksplisit dari workflow.
- Cleaning dipindahkan ke Call 2 agar pengguna dapat meninjau dan mengonfirmasi rekomendasi sebelum cleaning diterapkan.
- Bug sandbox Python terkait penggunaan list comprehension diperbaiki dengan pendekatan for-loop.
- Eksekusi run_python_repl dibatasi maksimal dua kali per sesi analisis untuk mengurangi looping dan pemanggilan Python yang tidak diperlukan.

9. Testing & Validation

9.1 Technical Testing

Test Case	Expected Result	Actual Result	Status
Dataset loading	Dataset berhasil dibaca	Dataset bank_transactions_data_edited.csv terbaca: 2.537 baris dan 16 kolom	✓
EDA	Informasi dataset tersedia	Ukuran data, tipe kolom, dan ringkasan kualitas data ditampilkan	✓
Missing detection	Missing value teridentifikasi	403 missing value terdeteksi (118 numerik, 285 kategorikal)	✓
Duplicate detection	Duplicate rows diperiksa	21 baris duplikat terdeteksi	✓
Clustering	Clustering berjalan jika memenuhi kondisi	3 segmen terbentuk (88, 1.407, dan 925 baris)	✓
Cleaning	Cleaning mengikuti pilihan user	Mengikuti rekomendasi: 21 duplikat dihapus, 27 target kosong dihapus, 90 numerik diisi median, 284 kategorikal diisi modus; 2.489 baris tersisa	✓
Target selection	Target dikonfirmasi	Agent menampilkan 4 kandidat dan menjalankan analisis setelah target AccountBalance dipilih	✓
Model screening	Tiga model dievaluasi	Tiga model dievaluasi (Random Forest, Linear Regression, Gradient Boosting)	✓
Baseline	Baseline dihitung	RMSE 3.973,17 dan R^2 -0,002	✓
Quality label	Threshold diterapkan	Gradient Boosting dan Random Forest SEDANG, Linear Regression KURANG MEMUASKAN, sesuai threshold	✓
Google Docs	Report berhasil dibuat	Setelah pengguna menjawab ya, laporan berhasil dibuat di Google Docs	✓
Error handling	Target tidak ada di dataset	Agent menyatakan kolom tidak ditemukan, lalu menampilkan 4 kandidat target valid yang harus dipilih	✓

9.2 User Validation

Validasi pengguna dilakukan sebagai validasi awal terhadap masalah dan konsep menggunakan survei n=4. Hasilnya dijelaskan pada Bagian 2.

10. Responsible AI

10.1 Data Minimization & Privacy

AutoData hanya membutuhkan dataset yang diperlukan untuk menjalankan workflow analisis. Credentials API disimpan di luar prompt dan tidak dimasukkan ke dalam dataset atau laporan.

10.2 Data yang Keluar dari Mesin Lokal

Ke Gemini: Agent menerima output yang dihasilkan workflow Python untuk menyusun respons percakapan. Informasi yang tersedia mencakup nama kolom, tipe data, statistik deskriptif, missing value, duplicate rows, rata-rata kolom numerik per cluster, hasil machine learning, serta nama fitur hasil get_dummies() yang dapat muncul pada output feature importance. Raw rows dataset tidak dicetak oleh Call 1 maupun Call 2 sebagai bagian dari output tool.

Ke Google Docs: hasil analisis yang telah tersedia digunakan untuk membentuk laporan Markdown melalui GOOGLEDOCS_CREATE_DOCUMENT_MARKDOWN. Laporan dapat memuat EDA, data quality, cleaning, clustering, hasil modeling, baseline, quality label, dan seluruh feature importance.

Jalur Telegram: Apabila pengguna memakai Telegram Bridge, file CSV dan pesan percakapan melewati server Telegram, dan respons berisi hasil analisis (ringkasan data, metric, quality label) dikirim kembali melalui Telegram. File CSV kemudian diunggah ke Langflow untuk diproses.

10.3 Retention & Deletion

Prototype saat ini belum menerapkan retention period dan mekanisme deletion otomatis. CSV diproses melalui Langflow pada mesin lokal. Laporan hasil analisis disimpan di Google Docs milik akun pengguna ketika fitur tersebut digunakan. Implementasi produksi memerlukan kebijakan retention dan deletion yang menetapkan durasi penyimpanan dataset, hasil analisis, dan dokumen yang dibuat.

10.4 User Control

- Pengguna mengontrol pilihan cleaning.
- Pengguna mengontrol target analysis.
- Pembuatan laporan Google Docs dilakukan setelah permintaan pengguna.

10.5 Transparency & Uncertainty

System membedakan antara hasil dari Python/tool, hasil perhitungan metric, rekomendasi, interpretasi, dan keterbatasan. Metric disertai baseline dan quality label. Hasil dengan performa rendah tetap disampaikan tanpa dipaksakan menjadi kesimpulan positif.

10.6 Bias & Fairness

Feature importance menunjukkan kontribusi statistik terhadap prediksi dan tidak membuktikan hubungan sebab-akibat. Fairness testing antar kelompok demografis belum diimplementasikan pada prototype saat ini.

10.7 High-Impact Decisions

AutoData hanya digunakan untuk initial analysis dan screening. Prototype tidak dirancang untuk mengambil keputusan otomatis dalam konteks high-impact seperti seleksi pekerjaan, persetujuan kredit, diagnosis medis, atau keputusan consequential lainnya.

11. Scope & Limitations

11.1 Current Scope

- CSV analysis
- EDA
- Data Quality Checking
- Cleaning Recommendation
- Clustering
- Target Recommendation
- Regression/Classification Screening
- Three-Model Comparison
- Baseline Comparison
- Quality Label
- Google Docs Report

11.2 Current Limitations

- Belum merupakan production deployment.
- Belum menggunakan hyperparameter optimization.
- Belum menggunakan cross-validation.
- Fairness testing belum tersedia.
- Quality threshold bersifat heuristic.
- Native CSV upload pada Bob masih terbatas.
- Python interpreter memiliki pembatasan tertentu.
- Belum ditujukan untuk high-impact decision making.
- Laporan Google Docs disusun oleh LLM dari output Python, sehingga angka pada laporan perlu diverifikasi terhadap output tool.

12. Conclusion & Next Development

AutoData menunjukkan prototype workflow analisis data berbasis percakapan yang mengintegrasikan IBM Bob, MCP, dan IBM Langflow dengan pemrosesan Python dan machine learning screening.

Pendekatan utama AutoData adalah menggabungkan workflow yang terarah, kontrol pengguna pada keputusan tertentu, dan baseline comparison untuk memberikan konteks terhadap hasil model.

Secara bisnis, AutoData menggunakan pendekatan freemium dengan detail yang dijelaskan pada Idea & Business Canvas.

Pengembangan berikutnya mencakup direct file upload yang lebih sederhana, cross-validation dan evaluasi model yang lebih kuat, fairness testing, serta koneksi database untuk workflow analisis yang lebih berkelanjutan.

Appendix

A. Quick Start

Prerequisites: IBM Bob, IBM Langflow, Gemini API key, Composio API key, AutoData Langflow flow, dan akun Google untuk pembuatan laporan.

1. Install dan jalankan Langflow.
2. Siapkan Gemini API key.
3. Siapkan Composio API key.
4. Import flow AutoData ke Langflow.
5. Uji flow terlebih dahulu melalui Langflow Playground.
6. Expose flow melalui MCP.
7. Konfigurasikan IBM Bob sebagai MCP client.
8. Uji satu prompt eksplisit menggunakan dataset yang telah disiapkan.

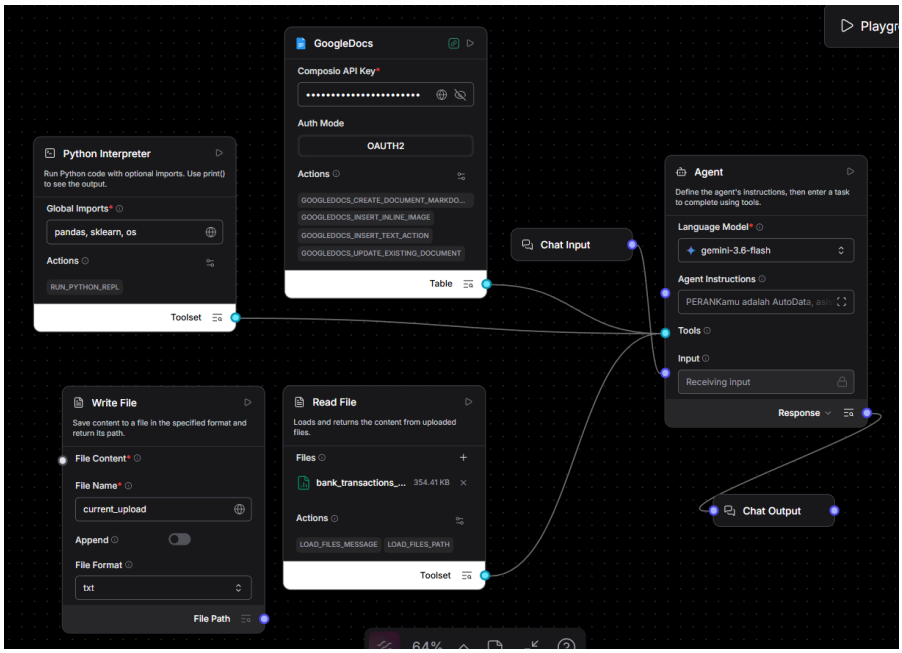
Konfigurasi MCP Bob menggunakan args berikut:

```
"args": [
    "--with",
    "mcp<2.0.0"
]
```

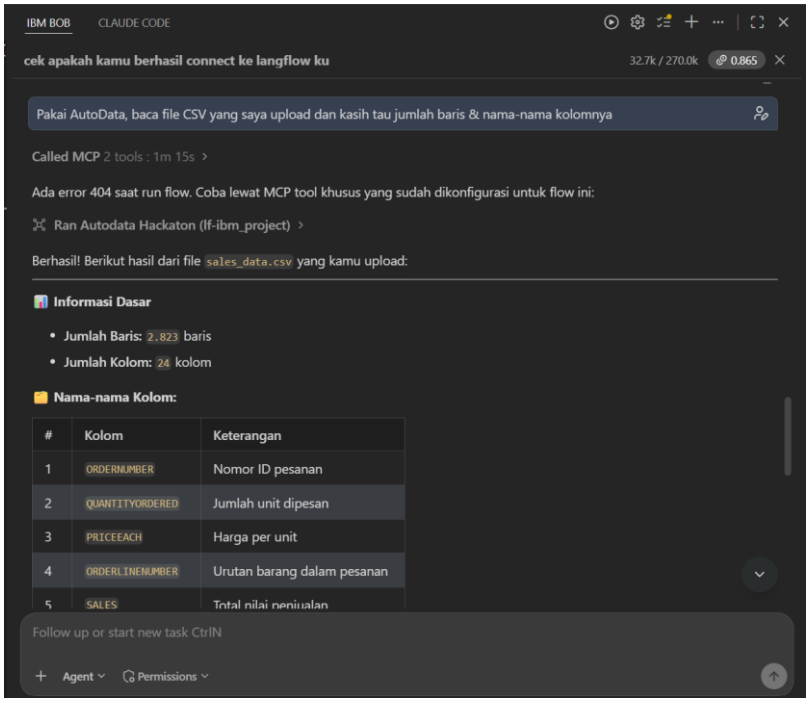
B. Glossary

Istilah	Penjelasan
MCP	Protokol yang memungkinkan aplikasi AI menemukan dan memanggil tools dari sistem lain.
Baseline	Metode pembanding sederhana untuk memberikan konteks pada performa model.
R^2	Metric regression yang menunjukkan proporsi variasi target yang dapat dijelaskan oleh model.
Accuracy	Proporsi prediksi classification yang benar.
Balanced Accuracy	Rata-rata recall per kelas yang digunakan sebagai konteks tambahan pada classification.
Clustering	Teknik unsupervised learning untuk mengelompokkan observasi berdasarkan pola tertentu.
Feature Importance	Ukuran kontribusi relatif fitur terhadap prediksi model.

C. Reproduction Evidence



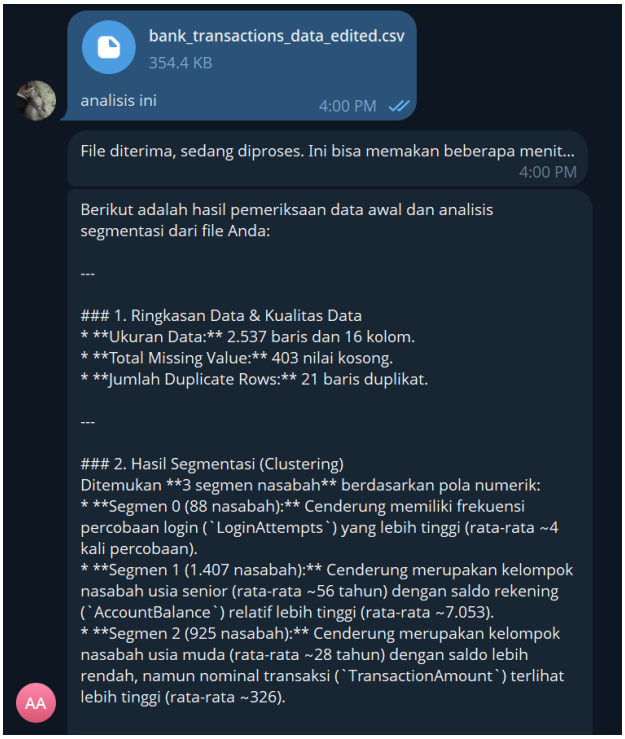
Gambar 4. Canvas Langflow: Agent, Python Interpreter, GoogleDocs, dan Read File.



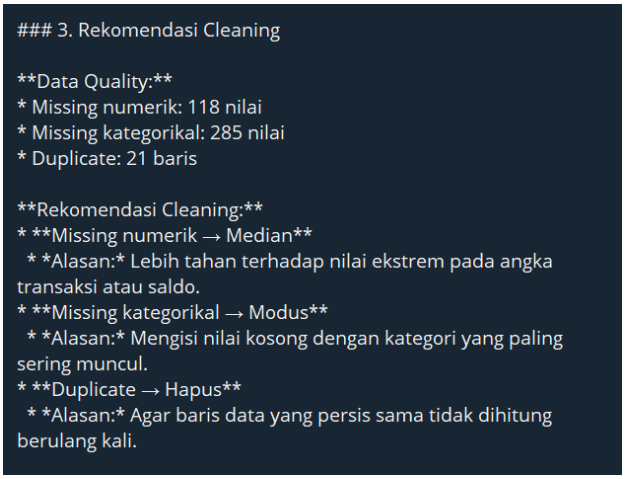
Gambar 5. IBM Bob memanggil flow AutoData melalui MCP (tool autodata_hackaton).



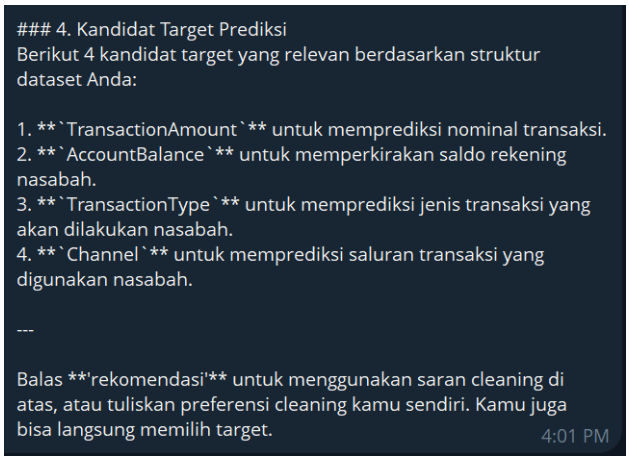
Gambar 6. Konfigurasi MCP Bob (.bob/mcp.json), API key disamarkan.



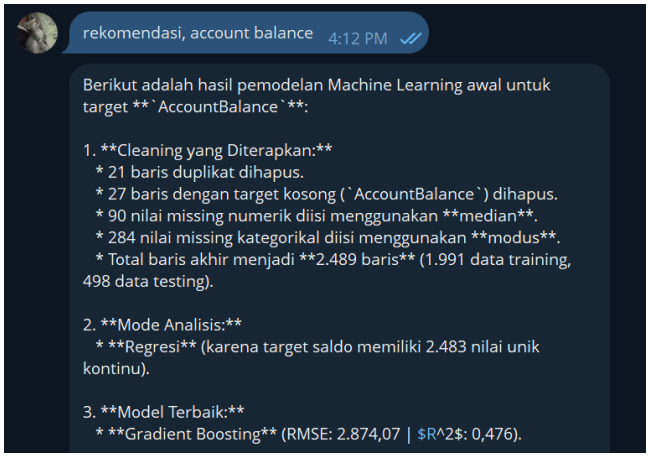
Gambar 7. Call 1 melalui Telegram: ringkasan data dan clustering.



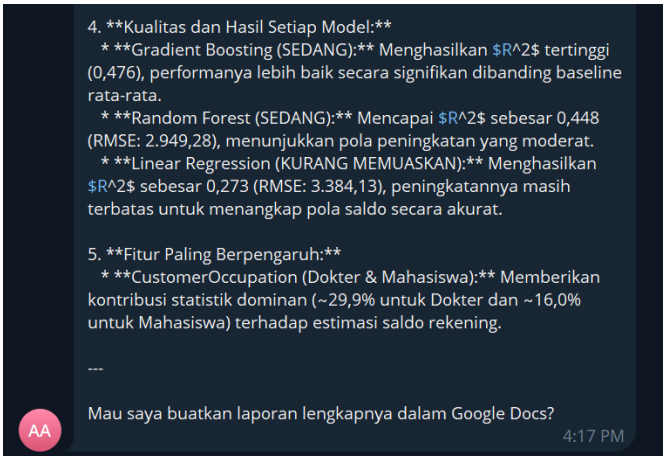
Gambar 8. Rekomendasi cleaning melalui Telegram.



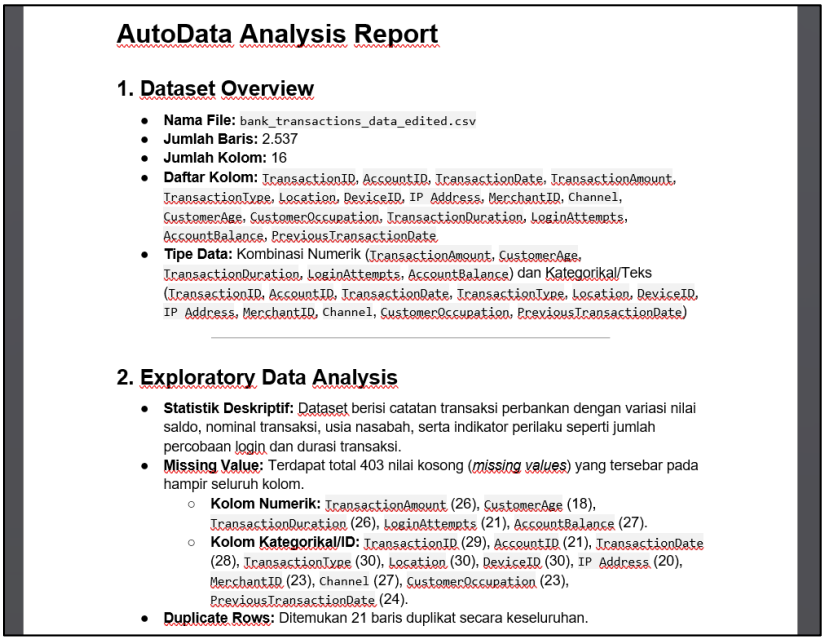
Gambar 9. Kandidat target dan permintaan pilihan pengguna melalui Telegram.



Gambar 10. Call 2 melalui Telegram: cleaning yang diterapkan dan hasil model.



Gambar 11. Quality label dan fitur paling berpengaruh melalui Telegram.



AutoData Analysis Report

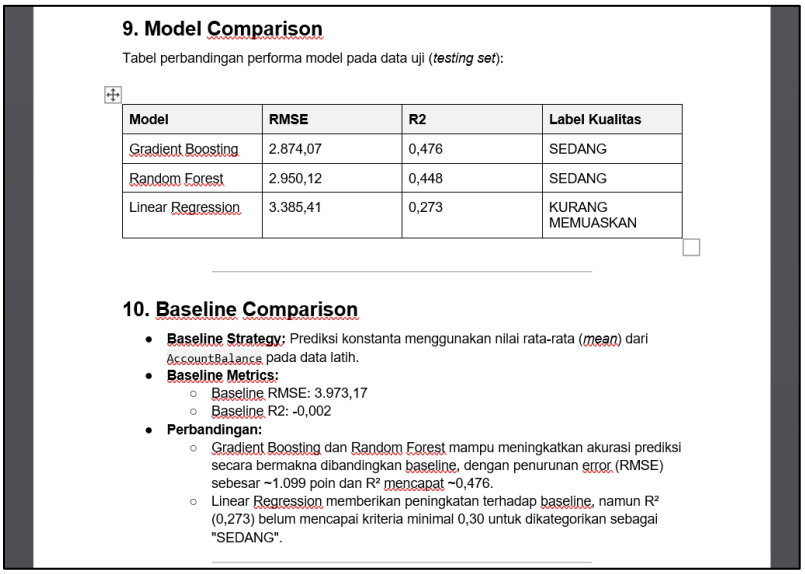
1. Dataset Overview

- **Nama File:** `bank_transactions_data_edited.csv`
- **Jumlah Baris:** 2.537
- **Jumlah Kolom:** 16
- **Daftar Kolom:** TransactionID, AccountID, TransactionDate, TransactionAmount, TransactionType, Location, DeviceID, IP Address, MerchantID, Channel, CustomerAge, CustomerOccupation, TransactionDuration, LoginAttempts, AccountBalance, PreviousTransactionDate
- **Tipe Data:** Kombinasi Numerik (TransactionAmount, CustomerAge, TransactionDuration, LoginAttempts, AccountBalance) dan Kategorikal/Teks (TransactionID, AccountID, TransactionDate, TransactionType, Location, DeviceID, IP Address, MerchantID, Channel, CustomerOccupation, PreviousTransactionDate)

2. Exploratory Data Analysis

- **Statistik Deskriptif:** Dataset berisi catatan transaksi perbankan dengan variasi nilai saldo, nominal transaksi, usia nasabah, serta indikator perilaku seperti jumlah percobaan login dan durasi transaksi.
- **Missing Value:** Terdapat total 403 nilai kosong (*missing values*) yang tersebar pada hampir seluruh kolom.
  - **Kolom Numerik:** TransactionAmount (26), CustomerAge (18), TransactionDuration (26), LoginAttempts (21), AccountBalance (27).
  - **Kolom Kategorikal/ID:** TransactionID (29), AccountID (21), TransactionDate (28), TransactionType (30), Location (30), DeviceID (30), IP Address (20), MerchantID (23), Channel (27), CustomerOccupation (23), PreviousTransactionDate (24).
- **Duplicate Rows:** Ditemukan 21 baris duplikat secara keseluruhan.

Gambar 12. Laporan Google Docs yang dihasilkan bagian 1.



9. Model Comparison

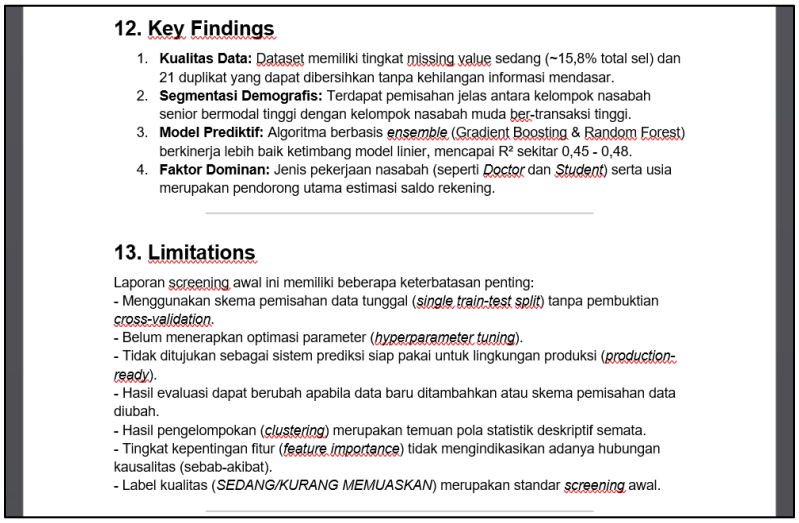
Tabel perbandingan performa model pada data uji (*testing set*):

Model	RMSE	R2	Label Kualitas
Gradient Boosting	2.874,07	0,476	SEDANG
Random Forest	2.950,12	0,448	SEDANG
Linear Regression	3.385,41	0,273	KURANG MEMUASKAN

10. Baseline Comparison

- **Baseline Strategy:** Prediksi konstanta menggunakan nilai rata-rata (*mean*) dari `AccountBalance` pada data latih.
- **Baseline Metrics:**
  - Baseline RMSE: 3.973,17
  - Baseline R2: -0,002
- **Perbandingan:**
  - Gradient Boosting dan Random Forest mampu meningkatkan akurasi prediksi secara bermakna dibandingkan baseline, dengan penurunan error (RMSE) sebesar ~1.099 poin dan R^2 mencapat ~0,476.
  - Linear Regression memberikan peningkatan terhadap baseline, namun R^2 (0,273) belum mencapai kriteria minimal 0,30 untuk dikategorikan sebagai "SEDANG".

Gambar 13. Laporan Google Docs yang dihasilkan bagian 2.



12. Key Findings

1. **Kualitas Data:** Dataset memiliki tingkat missing value sedang (~15,8% total sel) dan 21 duplikat yang dapat dibersihkan tanpa kehilangan informasi mendasar.
2. **Segmentasi Demografis:** Terdapat pemisahan jelas antara kelompok nasabah senior bermodal tinggi dengan kelompok nasabah muda ber-transaksi tinggi.
3. **Model Prediktif:** Algoritma berbasis *ensemble* (Gradient Boosting & Random Forest) berkinerja lebih baik ketimbang model linier, mencapai R^2 sekitar 0,45 - 0,48.
4. **Faktor Dominan:** Jenis pekerjaan nasabah (seperti *Doctor* dan *Student*) serta usia merupakan pendorong utama estimasi saldo rekening.

13. Limitations

Laporan screening awal ini memiliki beberapa keterbatasan penting:
- Menggunakan skema pemisahan data tunggal (*single train-test split*) tanpa pembuktian *cross-validation*.
- Belum menerapkan optimasi parameter (*hyperparameter tuning*).
- Tidak ditujukan sebagai sistem prediksi siap pakai untuk lingkungan produksi (*production-ready*).
- Hasil evaluasi dapat berubah apabila data baru ditambahkan atau skema pemisahan data diubah.
- Hasil pengelompokan (*clustering*) merupakan temuan pola statistik deskriptif semata.
- Tingkat kepentingan fitur (*feature importance*) tidak mengindikasikan adanya hubungan kausalitas (sebab-akibat).
- Label kualitas (*SEDANG/KURANG MEMUASKAN*) merupakan standar *screening* awal.

Gambar 14. Laporan Google Docs yang dihasilkan bagian 3.

- Flow export JSON

  tersedia di *Flow/AutoData Flows Langflow.json*

D. MCP Configuration

```
{
  "mcpServers": {
    "langflow": {
      "command": "uvx",
      "args": ["--from", "lfx", "lfx-mcp"],
      "env": {
        "LANGFLOW_SERVER_URL": "http://localhost:7860",
        "LANGFLOW_API_KEY": "<REDACTED>"
      }
    },
    "lf-ibm_project": {
      "command": "uvx",
      "args": [
        "--with", "mcp<2.0.0",
        "mcp-proxy",
        "--transport", "streamablehttp",
        "--headers", "x-api-key", "<REDACTED>",
        "http://localhost:7860/api/v1/mcp/project/<PROJECT_ID>/streamable"
      ],
      "alwaysAllow": ["<PROJECT_NAME>"]
    }
  }
}
```

E. Environment & Configuration Notes

- IBM Langflow versi 1.12.0, berjalan lokal di http://localhost:7860
- Python Interpreter: Global Imports pandas, sklearn, os (karena itu kode tidak memakai baris import)
- Agent: Max Iterations 15, Stream aktif, riwayat chat 100 pesan, tool Current Date dan Calculator aktif
- Tool pada Agent: Read File (load_files_path), Python Interpreter (run_python_repl), dan GoogleDocs lewat Composio
- Model LLM: Gemini 3.6 Flash dan Gemini 3.7 Flash
- Variabel konfigurasi (nilai tidak dicantumkan): LANGFLOW_SERVER_URL, LANGFLOW_API_KEY, API key model, API key Composio
- MCP dijalankan lewat uvx dengan paket lfx-mcp dan mcp-proxy
- Telegram Bridge dijalankan terpisah dan source code-nya tidak disertakan